

Relatório Provisório da Pesquisa: Impactos da Pandemia na Ocupação dos Jovens no Mercado de Trabalho brasileiro

1. Introdução

Este relatório documenta, passo a passo, o desenvolvimento da presente pesquisa, que objetiva, em linhas gerais, mensurar o impacto do choque econômico no contexto da pandemia de COVID-19 sobre a ocupação juvenil no mercado de trabalho. Mais propriamente, dentro do referencial teórico do Modelo de Search & Matching de Diamond-Mortensen-Pissarides (DMP), estimar as probabilidades condicionadas (Cadeias de Markov) de transição entre emprego e desemprego, com foco na integração dos jovens no setor laboral, e complementação com a mensuração de heterogeneidades no impacto dado diferentes características individuais (como sexo, raça, escolaridade, localidade, experiência), mas sobretudo, aplicação do referido modelo para regressão da eficiência de matching para o público-alvo.

Para este fim, utilizou-se microdados da PNAD Contínua Trimestral (2019-2022) e dados de admissões formais disponibilizados pelo CAGED como proxy para o estoque de vagas.

2. Construção do Painel Longitudinal da PNADC

2.1. Obtenção dos Dados

Foram utilizados microdados da PNAD Contínua Trimestral, para os anos de 2019 a 2022, coletados a partir do módulo *PNAD_SOCIAL* do STATA, desenvolvido pelo projeto Data Zoom da PUC Rio, que permite o emparelhamento dos indivíduos consultados pelo IBGE a partir da técnica proposta por Ribas e Soares (2008). Assim, às variáveis padrão são adicionados novos elementos de identificação *hous_id* e *ind_id* para identificação do domicílio e do indivíduo, respectivamente, caso sejam sorteados novamente na nova amostra. Estas informações serão úteis para a observação do mesmo indivíduo em dois ou mais trimestres consecutivos e registro de sua evolução no mercado de trabalho, para posterior geração das matrizes de transição e regressões contra as suas características e os períodos de análise, especialmente o que antecede e o em que se vive a pandemia.

O módulo aplicado às planilhas trimestrais da PNADC, baixadas diretamente do portal do IBGE (<https://www.ibge.gov.br/estatisticas/sociais/trabalho/9171-pesquisa-nacional-por-amostra-de-domicilios-continua-mensal.html?=&t=microdados>), retornou quatro arquivos de

dados .dta para cada ano de análise. Estes foram, em seguida, importados para o R, onde foram unidos em um mesmo banco de dados, via empilhamento, e feito o filtro das variáveis relevantes, conforme o script *importação_filtro.R*, tratado a seguir.

2.2. Filtragem dos Dados

No processo de filtro dos dados da PNADC já limpos e emparelhados pelo módulo anterior, prosseguimos para a seleção apenas das variáveis relevantes para o método desta pesquisa. Seguindo o convencionado pelo IBGE e estudos da OIT sobre mercado de trabalho, consideramos como Jovens apenas indivíduos na faixa etária de 14 a 29 anos de idade, e filtramos, restringindo às observações cuja variável de código *V2009* (que indica a idade relatada na semana de referência) se situassem neste intervalo de idades.

Para identificação do indivíduo, além das variáveis de emparelhamento geradas pela ferramenta do Data Zoom (*ind_id* foi renomeada para *id_pessoa*), e da idade, selecionamos variáveis idiossincráticas que podem ser úteis para análise dos impactos heterogêneos entre os mesmos jovens, como:

- *V2007*: Sexo (se homem, 1; se mulher, 2)
- *V1022*: Situação do domicílio (se urbana, 1; se rural, 2)
- *V2010*: Cor ou raça (branca, 1; preta, 2; parda, 4; e outras)

Seguindo a literatura que compõem o referencial teórico da pesquisa, consideramos a questão da acumulação de experiência, além da qualificação, na inclusão e manutenção no mercado de trabalho. Como não existe nenhuma forma direta de mensurar esta dimensão do capital humano, consideramos como proxy do que denominamos “experiência” a idade do indivíduo, mas propriamente construímos três faixas de idade no intervalo etário de estudo: Adolescente (14-17), Jovem (18-24) e Jovem adulto (25-29).

Para análise do estado ocupacional, dentro do arcabouço do modelo de Search & Matching, é conveniente trabalhar apenas com jovens dentro da força de trabalho, o que nos levou à seleção das seguintes variáveis ocupacionais:

- *VD4001*: Condição em relação a força de trabalho (na força de trabalho, 1; fora da força de trabalho, 2)
- *VD4002*: Condição de ocupação (ocupada, 1; desocupada, 2)

Assim, criamos uma variável indicadora, *estado_ocupacional*, que assume valor 1 para as observações em que se está dentro da força de trabalho e ocupado, ou 0, para aquelas em que se está desocupado, mas ainda assim está dentro da força de trabalho. Ou seja, observar apenas jovens que estão ativamente no mercado de trabalho, seja trabalhando, seja buscando emprego.

Concluída esta etapa, de definição do conjunto de dados sobre os quais queremos proceder nossas análises dos impactos do choque econômico desencadeado pela pandemia de COVID-19 sobre a transição dos jovens no mercado de trabalho, passamos para a estimação dessas transições.

3. Construção da Matriz de Markov

Para a confecção das matrizes de transição a lá Markov, principiamos o emparelhamento de observações consecutivas do estado ocupacional de um mesmo indivíduo. Para isso, inicialmente ordenamos os dados por código de identificação individual, ano e trimestre, a fim de organizarmos observações do mesmo indivíduo uma abaixo da outra. Em seguida, agrupamos todas as observações pelo mesmo id, criamos variável *estado_t1* e armazenamos nela o estado ocupacional da observação posterior. Analiticamente isso significa,

$$E_{t1_t} = E_{t+1}$$

Depois, aplicamos um filtro para garantir que estejamos observando apenas registros consecutivos, ou seja, trimestre após trimestre, para que seja possível capturar as transições no espaço de um trimestre.


Com as informações contidas nestas duas variáveis, *estado_ocupacional* e *estado_t1*, conseguimos criar uma matriz que os unem como pares ordenados e contabilizam quantas vezes cada uma dessas combinações aparecem no conjunto de dados. Dividindo cada medida pelo total de observações, obtivemos as proporções, ou probabilidades condicionais de transição entre os estados ocupacionais 0 e 1, ou seja, entre o desemprego e emprego.

Como o que nos interessa são as matrizes de cada período de análise para comparação posterior, geramos uma função que estima matrizes de Markov para cada categoria da variável *período* especificada. Por exemplo, a seguinte tabela com matrizes para cada espaço temporal foi confeccionada:

Pré-pandemia			Durante pandemia		Pós-pandemia	
	Desemprego	Emprego	Desemprego	Emprego	Desemprego	Emprego
Desemprego	0,628	0,372	0,798	0,202	0,542	0,458
Emprego	0,068	0,932	0,049	0,951	0,052	0,948

A partir desses dados, já foram possíveis verificações de muitas afirmações da literatura consultada e adotadas como hipóteses de pesquisa, como a histórica dificuldade de inclusão juvenil no mercado de trabalho. Antes mesmo da pandemia, embora só esteja sendo observada as proporções de transição do ano de 2019, pode-se afirmar que, as chances de ingresso de um jovem no mercado de trabalho entre um trimestre e outro, controlada por todas as variáveis pessoais que possam impactar isso, são baixíssimas ($\approx 37,2\%$). Em média, a pandemia realmente teve um impacto negativo, reduzindo-as para cerca de 20,2%; o que pode ser explicado pela redução da atividade econômica, mas não pela rotatividade ou desemprego, já que a probabilidade de transição para o desemprego caiu, e a de permanência no emprego, aumentou (na verdade, nos três períodos, é muito alta). Já a explicação dos dados de retomada é um desafio a hipótese de trabalho, que supunha uma deterioração da participação dos jovens no mercado de trabalho; no entanto, as especulações não ficam de todas equivocadas, dado que a expansão dos serviços de delivery, especialmente por conta das restrições de aglomeração e trânsito durante a pandemia, tem uma fisionomia juvenil. Em outras palavras, o jovem encontrou nesse tipo de prestação de serviços um mercado laboral alternativo, dado a dificuldade de integração ao mercado formalizado.

Graficamente ficará melhor a visualização dessas chances de transição nos diferentes cenários estudados:




É visível que as chances de conseguir uma ocupação em um intervalo de três meses, para os jovens de 14 a 29 anos, é baixíssima, e, portanto, o tempo no desemprego é desalentador,

especialmente no período pandêmico. Mas a diferença entre as chances de ficar desempregado e de conseguir emprego se reduzem no pós-pandemia. Que mudanças na distribuição dos postos de trabalho, por exemplo, podem explicar esse fenômeno? Em pouco tempo as características do jovem que o tornam atrativo para o mercado de trabalho, e, portanto, dentro da visão do modelo DMP, aumentam a eficiência do matching, não devem ter mudado muito; mas, como se dá a distribuição dessas especificidades, e como ela impacta nas chances de o trabalhador conseguir uma ocupação nessa “nova economia”? Prosseguimos então com a geração de matrizes por grupo de características individuais.

3.1. Matrizes por Grupo e Período

Para geração dessas matrizes segmentadas tornamos explícitas as variáveis selecionadas no processo de filtragem, e criamos uma função a partir da qual possam ser geradas todas as matrizes de subgrupos.

O seguinte gráfico com as probabilidades de transição pode ser gerado:




Quanto aos padrões de inclusão, segue-se o já observado na literatura, a pandemia apenas reduz as chances em escala, sem alterar as relações intragrupo. Quanto maior a idade, e na nossa abordagem, maior a experiência, maior as chances de conseguir um emprego; mulheres estão em desvantagem em relação aos homens; maior escolaridade acompanha maior integração, apesar de a diferença ser marginal entre quem tem Ensino Médio e quem tem apenas o Fundamental ou menos; jovens de áreas urbanas tem mais facilidade de transição para o emprego que jovens de regiões rurais, devido a um mercado de trabalho mais espesso.

No entanto, uma configuração nos parece interessante à investigação da pesquisa, pessoas de outras cores ou raças têm vantagens em relação às brancas, no processo de integração ao mercado de trabalho. Preliminarmente, pode-se afirmar que isto está associado a composição dos setores e postos de trabalho, a uma economia de empregos de baixa qualidade e amplo setor

informal, dado às desigualdades raciais consagradas na literatura de ciências sociais. Mas não se deve apegar a esta hipótese, pois os dados da pandemia podem esclarecer que não passa de um grande preconceito, e quem vai discordar dos números?

A pandemia, como já constatado, reduziu igualmente todas as probabilidades de inserção, mas significativamente achatou todas as chances associadas a categorias de raça e origem, elevou a adesão de quem tem fundamental ou menos, e significativamente zerou os de quem tem o ensino médio. Por outro lado, elevou todas as chances de ficar desempregado, e, portanto, o tempo no desemprego.



A retomada que se torna um objeto interessante da pesquisa, mais propriamente, as mudanças no durante pandemia, e o rearranjo da economia na recuperação, que explicam a melhora das chances de emprego, quando o que se vê na literatura é desmantelamento das cadeias de produção, crescente substituição da mão de obra humana por capital tecnológico e otimização de processos.

4. Modelagem Econométrica da Inclusão Juvenil no Mercado de Trabalho

Seguimos então para a modelagem econométrica dessas relações. Como o papel metodológico da pesquisa é aplicar o modelo Diamond-Mortensen-Pissarides ao estudo dos efeitos da pandemia, e, particularmente, o nosso interesse é mensurar essa reverberação no segmento juvenil da força de trabalho, empreenderemos uma estimação da eficiência do matching, que depende, além da disponibilidade de vagas e número de desempregados, de características dos trabalhadores que determinem sua eficiência e seu poder de barganha. Por isso, antes rodamos regressões Logit para as características, visando ver as que afetam a

probabilidade de transição do emprego com alguma significância estatística, inclusive analisando suas interações com o tempo.

Neste objetivo, inicialmente criamos a variável *transição_emprego* que foi nossa variável resposta nas especificações dos modelos. Ela assume valor 1 se a pessoa saiu do desemprego para o emprego, ou seja, se observações cuja variável *estado_ocupacional* é 0 têm como 1 o valor de *estado_t1*.

Após isso, como as especificações dos modelos foram tais que os coeficientes das variáveis explicativas fossem estimados em relação a um grupo base (homem, branca, fundamental ou menos, adolescente (14-17), urbano, pré-pandemia), criamos uma variável binária para mulher (que assume valor 1 se for; 0, caso contrário) e transformamos as outras e fator, tal que permita ao R criar dummies para cada grupo automaticamente.

A primeira especificação do modelo não considerou a interação com o tempo, e assumiu a seguinte forma:

$$P(Y_{it+1} = 1|X_{it}) = \text{logit}^{-1}(X)_{it}'$$

Onde:

- Y_{it+1} : variável dependente *transição_emprego* = 1 se ocorreu transição de desempregado para empregado.
- X_{it} : vetor de características individuais (sexo, raça, escolaridade, etc.) no tempo t.

Os coeficientes de cada variável assumem a forma de log-odds, de forma que se pode dizer que, o coeficiente da variável binária mulher é o efeito de ser mulher comparado a homem, que o coeficiente de *periodoDurante pandemia* é o efeito da pandemia comparado ao pré-pandemia, e assim por diante.

Em código R, a regressão tem a seguinte fórmula:

```
1. modelo_logit <- glm(transicao_emprego ~ mulher + raca + escolaridade + localidade +  
2. experiencia + periodo, data = microdados_transicao, family = binomial)
```

Para obter os coeficientes Odds-ratios (o quanto a elasticidade de uma variável representa da elasticidade da variável base), aplicou-se o exponencial aos coeficientes em log-odds obtidos do sumário da regressão. Ademais, considerou-se significativo apenas estimativas a um grau de 0.05 de significância. Abaixo, o sumário obtido:

```
Call:
glm(formula = transicao_emprego ~ mulher + raca + escolaridade +
    localidade + experiencia + periodo, family = binomial, data = microdados_transicao)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-3.24177	0.41896	-7.738	1.01e-14	***
mulher	0.14207	0.01479	9.603	< 2e-16	***
racaPreta	0.41484	0.02531	16.387	< 2e-16	***
racaParda	0.35210	0.01639	21.484	< 2e-16	***
racaOutros	0.32443	0.07496	4.328	1.51e-05	***
escolaridadeMédio	-0.31671	0.71735	-0.442	0.65885	
escolaridadeSuperior	0.43245	0.41548	1.041	0.29794	
localidadeCapital	0.23352	0.01834	12.732	< 2e-16	***
experienciaJovem (18-24)	-0.16797	0.05389	-3.117	0.00183	**
experienciaJovem adulto (25-29)	-0.61899	0.05441	-11.376	< 2e-16	***
periodoDurante pandemia	-0.45900	0.01671	-27.470	< 2e-16	***
periodoPós-pandemia	-0.08904	0.01875	-4.748	2.05e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 157300 on 380098 degrees of freedom
 Residual deviance: 154718 on 380087 degrees of freedom
 (128275 observations deleted due to missingness)

Estes resultados nos permitem fazer algumas inferências:

- Raças não-brancas tem consistentemente mais chances de conseguir emprego.
- Mulheres, que historicamente tinham menos chances, estão com 15% a mais que os homens.
- O maior dinamismo urbano permite aos jovens dessas regiões uma vantagem de 26% sobre os das áreas rurais.
- Jovens adultos (25-29) têm grande dificuldade de inserção, e por outro lado, quanto mais novo menor a desvantagem em relação aos adolescentes.
- Período da pandemia teve efeito fortemente negativo (-37%), com recuperação parcial no pós (-9%);
- Ter ensino superior ou ao menos o Médio, nesse período, não altera significativamente as chances de transição comparado ao fundamental.

Aqui se confirma, para o período em análise, que, as desigualdades raciais têm pouco efeito sobre o processo de inserção no mercado de trabalho. Como também, que, houve uma melhora significativa na presença das mulheres; o que pode ser parcialmente explicado pela expansão de setores em que elas compõem uma porção significativa da força de trabalho, como o setor de saúde e de cuidados.

No sentido contrário do observado na análise das matrizes de transição por experiência, os resultados da regressão mostram uma maior dificuldade dos mais velhos em aos adolescentes

para ingressar no mercado de trabalho. No período pandêmico, especificamente, podemos supor que os mais velhos, devido ao maior risco de vida, foram preteridos aos mais novos, e isto resulte em um maior tempo de desemprego; ou, maior informalidade da economia, que implique, agora seguindo o modelo de Search do McCall, em maior rejeição de ofertas pelos mais velhos, que são mais exigentes em termos de salário e estabilidade.

Claramente as áreas rurais foram as mais afetadas pela redução da atividade econômica, especialmente devido às medidas de restrição.

De fato, mais uma confirmação é feita do choque negativo da pandemia sobre a ocupação dos jovens no mercado de trabalho. E, de acordo com as estimativas, escolaridade não determinou maior ou menor grau de vulnerabilidade ao choque.

Ainda no esforço de entender o papel da heterogeneidade dos agentes no seu desempenho no mecanismo de matching, avançamos em uma especificação que considere as interações das características com os períodos. Ou seja, caberá a pergunta se, estatisticamente, ser mais jovem, e, portanto, ter menos experiência, ou ter um nível de escolaridade menor e - se considerarmos ter alguma relação causal - ser menos produtivo reduz as chances de admissão, em um cenário de redução da atividade econômica e muitas incertezas.

Nesta nova especificação utilizamos uma regressão logit onde, além de mensurar os efeitos isolados (já feitos na regressão anterior), mensuramos sua interação com o período P , sempre em relação às variáveis bases. No caso da interação com o tempo, é em relação ao período pré-pandêmico. Assim fica o modelo:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X + \beta_2 P + \beta_3 (X \times P) + \dots$$

Sua expressão em R:

```
1. modelo_interacoes <- glm(transicao_emprego ~ mulher * periodo + raca * periodo +  
2. escolaridade * periodo + localidade * periodo + experiencia * periodo,  
3. data = microdados_transicao, family = binomial)
```

Abaixo, o sumário resultante:

```
Call:
glm(formula = transicao_emprego ~ mulher * periodo + raca * periodo +
     escolaridade * periodo + localidade * periodo + experiencia *
     periodo, family = binomial, data = microdados_transicao)

Coefficients:
(Intercept)                -4.194151      1.012716  -4.141 3.45e-05 ***
mulher                      0.156468      0.022998   6.804 1.02e-11 ***
periodoDurante pandemia    0.772659      1.174237   0.658 0.51053
periodoPós-pandemia        1.360137      1.251743   1.087 0.27722
racaPreta                   0.488409      0.039848  12.257 < 2e-16 ***
racaParda                   0.440727      0.025773  17.100 < 2e-16 ***
racaOutros                  0.241821      0.125283   1.930 0.05358 .
escolaridadeMédio          1.282138      1.245271   1.030 0.30320
escolaridadeSuperior       1.298107      1.009366   1.286 0.19842
localidadeCapital          0.256429      0.028311   9.058 < 2e-16 ***
experienciaJovem (18-24)   -0.158676     0.079773  -1.989 0.04669 *
experienciaJovem adulto (25-29) -0.625733     0.080669  -7.757 8.71e-15 ***
mulher:periodoDurante pandemia -0.065084     0.033991  -1.915 0.05552 .
mulher:periodoPós-pandemia  0.035537     0.038145   0.932 0.35153
periodoDurante pandemia:racaPreta -0.121462     0.058684  -2.070 0.03847 *
periodoPós-pandemia:racaPreta -0.123575     0.064371  -1.920 0.05489 .
periodoDurante pandemia:racaParda -0.168657     0.037615  -4.484 7.34e-06 ***
periodoPós-pandemia:racaParda -0.121130     0.042399  -2.857 0.00428 **
periodoDurante pandemia:racaOutros  0.088755     0.179200   0.495 0.62040
periodoPós-pandemia:racaOutros  0.177559     0.185663   0.956 0.33890
periodoDurante pandemia:escolaridadeMédio -10.359337    37.355906  -0.277 0.78154
periodoPós-pandemia:escolaridadeMédio -1.659437     1.768927  -0.938 0.34819
periodoDurante pandemia:escolaridadeSuperior -1.082615     1.167612  -0.927 0.35382
periodoPós-pandemia:experienciaJovem (18-24) -1.308413     1.244458  -1.051 0.29308
periodoDurante pandemia:localidadeCapital -0.025127     0.042193  -0.596 0.55149
periodoPós-pandemia:localidadeCapital -0.060047     0.047177  -1.273 0.20309
periodoDurante pandemia:experienciaJovem (18-24) -0.020861     0.125920  -0.166 0.86842
periodoDurante pandemia:experienciaJovem adulto (25-29) -0.007341     0.136404  -0.054 0.95708
periodoDurante pandemia:experienciaJovem adulto (25-29)  0.057411     0.127066   0.452 0.65140
periodoPós-pandemia:experienciaJovem adulto (25-29) -0.056524     0.137875  -0.410 0.68183
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Fora as relações já observadas nas matrizes de transição e na regressão anterior, pouca coisa pode-se dizer acerca da interação com o tempo, por baixa ou nenhuma significância das estimativas adicionais. De forma que, o que podemos afirmar, com pouco respaldo estatístico está resumido na seguinte tabela:

Grupo	Durante a pandemia	Pós-pandemia
Mulheres	Penalização leve (6%)	Recuperação total
Pardos	Penalização forte (15%)	Penalização persiste (11%)
Pretos	Penalização moderada (11%)	Sem penalização

Não satisfeitos, fizemos uma outra investida para estimar os efeitos da pandemia sobre os diferentes grupos de jovens, isso adotando um modelo DIF-IN-DIF, ou seja, que isole Diferenças em Diferenças com Heterogeneidade. Sua especificação foi a seguinte:

```
1. modelo_3fases <- glm(transicao_emprego ~ pandemia_fase * (mulher + raca + escolaridade +
2. localidade + experiencia), data = microdados_transicao, family = binomial)
```

Abaixo, o sumário da regressão:

```
Call:
glm(formula = transicao_emprego ~ pandemia_fase * (mulher + raca +
  escolaridade + localidade + experiencia), family = binomial,
  data = microdados_transicao)

Coefficients:
(Intercept)                -4.194151    1.012716   -4.141 3.45e-05 ***
pandemia_faseDurante pandemia    0.772659    1.174237    0.658 0.51053
pandemia_fasePós-pandemia      1.360137    1.251743    1.087 0.27722
mulher                        0.156468    0.022998    6.804 1.02e-11 ***
racaPreta                    0.488409    0.039848   12.257 < 2e-16 ***
racaParda                    0.440727    0.025773   17.100 < 2e-16 ***
racaOutros                   0.241821    0.125283    1.930 0.05358 .
escolaridadeMédio            1.282138    1.245271    1.030 0.30320
escolaridadeSuperior         1.298107    1.009366    1.286 0.19842
localidadeCapital            0.256429    0.028311    9.058 < 2e-16 ***
experienciaJovem (18-24)     -0.158676    0.079773   -1.989 0.04669 *
experienciaJovem adulto (25-29) -0.625733    0.080669   -7.757 8.71e-15 ***
pandemia_faseDurante pandemia:mulher -0.065084    0.033991   -1.915 0.05552 .
pandemia_fasePós-pandemia:mulher  0.035537    0.038145    0.932 0.35153
pandemia_faseDurante pandemia:racaPreta -0.121462    0.058684   -2.070 0.03847 *
pandemia_fasePós-pandemia:racaPreta -0.123575    0.064371   -1.920 0.05489 .
pandemia_faseDurante pandemia:racaParda -0.168657    0.037615   -4.484 7.34e-06 ***
pandemia_fasePós-pandemia:racaParda -0.121130    0.042399   -2.857 0.00428 **
pandemia_faseDurante pandemia:racaOutros  0.088755    0.179200    0.495 0.62040
pandemia_fasePós-pandemia:racaOutros  0.177559    0.185663    0.956 0.33890
pandemia_faseDurante pandemia:escolaridadeMédio -10.359337   37.355906   -0.277 0.78154
pandemia_fasePós-pandemia:escolaridadeMédio -1.659437    1.768927   -0.938 0.34819
pandemia_faseDurante pandemia:escolaridadeSuperior -1.082615    1.167612   -0.927 0.35382
pandemia_fasePós-pandemia:escolaridadeSuperior -1.308413    1.244458   -1.051 0.29308
pandemia_faseDurante pandemia:localidadeCapital -0.025127    0.042193   -0.596 0.55149
pandemia_fasePós-pandemia:localidadeCapital -0.060047    0.047177   -1.273 0.20309
pandemia_faseDurante pandemia:experienciaJovem (18-24) -0.020861    0.125920   -0.166 0.86842
pandemia_fasePós-pandemia:experienciaJovem (18-24) -0.007341    0.136404   -0.054 0.95708
pandemia_faseDurante pandemia:experienciaJovem adulto (25-29) 0.057411    0.127066    0.452 0.65140
pandemia_fasePós-pandemia:experienciaJovem adulto (25-29) -0.056524    0.137875   -0.410 0.68183
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Os resultados desta estimação corroboram os das anteriores. As generalizações possíveis estão organizadas na tabela abaixo:

Grupo	Durante Pandemia	Pós-pandemia
Mulheres	Penalizadas marginalmente (~6%)	Recuperadas (sem efeito no pós)
Pardos	Penalizados significativamente (~15%)	Penalização persiste (~11%)
Pretos	Penalizados (~11%)	Recuperação no pós
Outras Raças	Sem efeito claro	Sem efeito claro
Escolaridade	Sem interação significativa	—
Capital	Benefício mantido, sem mudança	—
Jovens (18-29)	Desvantagem consistente, mas sem mudança ao longo dos períodos	

Podemos concluir então que a pandemia penalizou especialmente os jovens pardos e, em menor grau, pretos e mulheres; e que, apenas as mulheres se recuperaram plenamente no pós-pandemia.

5. Estimação do Modelo de Search & Matching (DMP)

A nossa pretensão inicial de estimação do modelo DMP se refere especificamente à mensuração do tightness θ , ou tensão do mercado de trabalho, que é uma medida da eficiência de matching, para os jovens. Isso nos forneceria uma estimativa do grau de inclusão dos jovens no mercado de trabalho, e internalizado no modelo estrutural, possibilitaria observarmos o seu comportamento diante de choques simulados.

Iniciamos construindo um painel trimestral agregado. Adicionamos uma variável de transição para do desemprego para o emprego, tal qual a que criamos anteriormente, só que simétrica. Depois, agregamos os dados por período e calculamos as seguintes variáveis:

- Estoques:
 U : total de jovens desocupados, mas buscando trabalho
 E : total de jovens empregados
 $N = U + E$: total de jovens na força de trabalho
- De Transições:
 T_{UE} : Número de transições desempregado-empregado
 T_{EU} : Número de transições empregado-desempregado
- Indicadoras:
Taxas de transição: $f_t = T_{UE}/U$, $s_t = T_{EU}/E$
Taxa de desemprego: $u_t = U/(U + E)$
Vagas V_t : proxy (não coletada diretamente pelo IBGE), deve ser aproximada a partir da tightness.

Após, foi feita a especificação empírica do modelo de busca ou função de matching, que é:

$$M_t = m \cdot U_t^\alpha \cdot V_t^{1-\alpha}$$

Mas estimamos de forma log-linearizada a partir da seguinte função:

$$\log(f_t) = \beta_0 + \beta_1 \log(\theta_t) + \epsilon_t$$

Com:

$\beta_1 = 1 - \alpha$: estimativa da elasticidade da função de matching

$$\theta_t = \frac{V_t}{u_t}$$

No entanto, como não temos acesso ao estoque de vagas, nossa estratégia empírica inicial consistiu em utilizar como proxy a proporção de admissões, mas, apesar de gerar um coeficiente elevado (elasticidade > 1), trata-se de um caso de endogeneidade estrutural, pois $f_t = T_{UE}/U$ e $\theta_t = E/U$ são construídos com a mesma base.

Uma alternativa foi utilizar dados de ocupação total trimestral do IPEADATA como proxy para o estoque de vagas da economia (sabendo que isso pressupõe plena utilização da capacidade instalada). Apesar de teoricamente mais plausível, a elasticidade estimada foi negativa e não significativa, provavelmente pela rigidez do estoque de ocupados totais diante de variações específicas entre os jovens.

Por fim, utilizamos dados de admissões formais mensais disponibilizados pelo Novo CAGED. Agregamos as observações por trimestre, e construímos uma nova variável tightness, tal que:

$$\theta_{CAGED,t} = \frac{\text{Admissões formais}}{U_t}$$

Reestimamos a equação $\log(f_t) = \beta_0 + \beta_1 \log(\theta_t) + \epsilon_t$ e chegamos a um resultado que reforça a direção estabelecida pela teoria entre as variáveis, mas, a elasticidade continua insignificante.

Em resumo, as três alternativas de estimação da tightness resultam em:

- Com proxy interna (E/U): $\beta_1 \approx 1.33, R^2 > 0.6$ (mas enviesado)
- Com total de ocupados: $\beta_1 < 0$, não significativo
- Com CAGED: $\beta_1 = 0.30$, sinal correto, mas $p > 0.3$ (baixo poder estatístico)

6. Continuação

Estamos decidindo se reavemos algumas variáveis de modo a melhorar nossas estimativas, e então partir para o modelo estrutural, ou se, para isso, consideremos o banco de dados sem o filtro de idade, e só na regressão consideremos as interações relacionadas ao estrato juvenil.